פרויקט בחלופה למידת מכונה
במסגרת לימודי התמחות בהנדסת תוכנה 883589

שם הפרויקט: סיווג ז'אנר בשירים

שם התלמיד: ליאב אביטן

תעודת זהות: **327850061**

בית ספר: תיכון ליאו באק

שם המנחה: אולגה בוטמן

שנת לימודים: תשפ"ג

שם החלופה: למידת מכונה

תאריך ההגשה: אפריל, 2023

(נוצר ע"י ה-AI - Midjourney)

תוכן עניינים

מבוא:

הרקע לפרויקט

מוזיקה כיום היא חלק אינטגרלי מחיינו, והיא מגיעה בז'אנרים רבים ושונים. בניתוח מוזיקה, סיווג ז'אנר היא משימה חיונית וחשובה, ויש לה שימושים רבים כגון:

- המלצת מוזיקה - שירותי הזרמת מוזיקה כגון Spotify, Apple Music ועוד משתמשים בסיווג ז'אנר מוזיקה כדי להמליץ למשתמשים על שירים ופלייליסטים חדשים. על ידי ניתוח הרגלי ההאזנה וההעדפות של המשתמש, שירותים אלו יכולים להמליץ על שירים מז'אנרים דומים שהמשתמש עשוי ליהנות מהם.
- חיפוש מוזיקה - סיווג ז'אנר מוזיקה משמש גם במנועי חיפוש מוזיקה. לדוגמה, אם משתמש מחפש ז'אנר מסוים של מוזיקה, כגון קלאסית או ג'אז, התוכנה יכולה להשתמש בתכונת סיווג הז'אנר כדי לסנן את תוצאות החיפוש ולמצוא את המוזיקה שהוא מחפש מהר יותר.
- הפקה מוזיקלית - מפיקים מוזיקליים יכולים להשתמש בסיווג ז'אנר כדי לנתח את המאפיינים של הז'אנרים השונים שעליהם הם רוצים לדעת, וליצור מוזיקה חדשה שמתאימה לאותם ז'אנרים. לדוגמה, מפיק שרוצה ליצור שיר חדש של היפ הופ או מוזיקה אלקטרונית, יכול להשתמש בסיווג ז'אנר כדי לנתח את המאפיינים של אותו הז'אנר וליצור שיר שיתאים לקריטריונים של הז'אנר.

מטרת הפרויקט - לבנות מודל למידת מכונה שיכול לסווג במדויק ז'אנרים של מוזיקה (מתוך 10 קטגוריות), באמצעות מערך הנתונים של GTZAN. [1]

קהל היעד של הפרויקט - כל מי שמתעניין בניתוח מוזיקה, למידת מכונה ומדעי הנתונים. הפרויקט נועד לספק הבנה טובה יותר של טכניקות סיווג ז'אנר במוזיקה והיישומים המעשיים שלהן.

אופן הפעולה - הפרויקט יכלול מספר שלבים, הכולל עיבוד מוקדם של נתונים, מיצוי תכונות, בחירת מודל ושיפורו והערכת תוצאות המודל ושלב היישום. הפרויקט ישתמש באלגוריתמים מתקדמים של למידת מכונה, כגון CNN, מניפולציה מתמטית , ועוד כדי להשיג דיוק סיווג גבוה.

[1] קישור: https://www.kaggle.com/datasets/andradaolteanu/gtzan-dataset-music-genre-classification

תהליך המחקר

כיום, ישנן מאות של ז'אנרים שונים מסביב לעולם, ביניהם - פופ, רוק, מוזיקה אלקטרונית, היפ הופ, מוזיקה קלאסית ועוד.

סיווג הז'אנר כיום חשוב ממספר סיבות, ביניהן -

- ארגון מוזיקה: סיווג ז'אנר עוזר בארגון וסיווג ז'אנרים שונים של מוזיקה, ומקל על המשתמשים למצוא ולגלות מוזיקה שהם אוהבים.

- המלצות מותאמות אישית: פלטפורמות הזרמת מוזיקה ואפליקציות אחרות הקשורות למוזיקה משתמשות בסיווג ז'אנר כדי לספק המלצות מוזיקה מותאמות אישית למשתמשים על סמך היסטוריית ההאזנה וההעדפות שלהם.

- שיווק וקידום: חברות תקליטים ומפיקים מוזיקליים משתמשים בסיווג ז'אנר כדי למקד לקהלים ספציפיים ולקדם את המוזיקה שלהם בהתאם.

- מחקר מוזיקלי: מוזיקולוגים וחוקרים משתמשים בסיווג ז'אנר כדי לחקור את התפתחות המוזיקה לאורך זמן, לזהות מגמות ולחקור את המשמעות התרבותית של ז'אנרים שונים.

- זכויות יוצרים ורישוי: סיווג ז'אנר משמש גם בזכויות יוצרים ורישוי של מוזיקה, שכן לז'אנרים שונים עשויים להיות חוקי זכויות יוצרים ודרישות רישוי שונות.

לכן, יש צורך מתמיד של חברות הזרמת מוזיקה, מוזיקולוגים, חברות הפקת מוזיקה ועוד, לסיווג ז'אנר על מנת לגרום למשתמש חברת הזרמה (Spotify לדוגמא) להישאר יותר זמן באפליקציה, או לשימוש בזכויות יוצרים ורישוי ראויים שיכולים לחסוך טעויות רבות ביצירת זכויות היוצרים.

השימוש כיום בסיווג ז'אנרים מובנה בתוך יישומים ואתרים, ואין אפשרות לגשת אליו. לכן, בניתי קוד פתוח[2] ב-Github שכל אדם יוכל להשתמש בו בעזרת הוראות ההדרכה שכתבתי. נוסף על כך, בניתי גם יישום מותאם (שעליו יפורט בהמשך) כך שבזמן אמת ניתן לשים שיר ולקבל חיזוי לז'אנר השיר שהועלה באמצעות ספריית Gradio[3].

[2] קישור: https://github.com/L33TAv/GenreClassificationGTZAN-with-CNN
[3] קישור: https://gradio.app/

במהלך הפרוייקט, נעזרתי בפרוייקט ב-Kaggle של סיווג ז'אנר ב-CNN[4] שבו היתה פונקצית המרה ל-MFCC, ופונקציות נוספות שהשתמשתי והתאמתי למטרת הפרוייקט שלי (פונקצית הMFCC השארתי כמעט בשלמותה).

במהלך הפרוייקט השתמשתי ולמדתי על ספרית Librosa[5], השתמשתי ובניתי באמצעות Gradio אתר שפועל בצורה חיה, שבו אוכל ליישם את סיווג הז'אנר - שבו ניתן לשים שיר לסיווג וחיזוי ז'אנר/ז'אנרים אפשריים, יחד עם נתונים נוספים על השיר.

אתגרים מרכזיים

בעיות איתם צפוי הלומד להתמודד במהלך פיתוח הפרויקט - בעיה מרכזית שאני עלול להתמודד במהלך הפרוייקט, היא הרקע המתמטי שדורש הפרוייקט. כאמור, מדובר בסיווג מוזיקה ולכן בשלב עיבוד הנתונים תהיינה טרנספורמציות מתמטיות, חישובים ועיבודים עם ידע מתמטי שעוד לא רכשתי (כגון התמרת פוריה). נוסף על כך, החלק הארי של הספריות של הפרויקט בו אני משתמש משתנות ומתעדכנות כל הזמן - ולכן עלול להיווצר שינוי בזמן עבודה על הפרוייקט מבחינת הקוד שנכתב.

על איזה צורך הפרויקט עונה? איזה פתרון הפרויקט הזה בא לתת? - פרויקט זה עוסק בסיווג ז'אנר במוזיקה ונועד לתת מענה לצורך בסיווג מוזיקה, ביעילות המירבית, לז'אנר מתוך מכלול ז'אנרים שונים ונפרדים. צורך זה נובע מהכמות העצומה של מוזיקה הזמינה כיום, מה שעלול להקשות על המשתמשים לזהות ולהאזין למוזיקה התואמת את העדפותיהם. על ידי סיווג אוטומטי של מוזיקה לז'אנרים, משתמשים יכולים, בקלות רבה יותר, לגלות מוזיקה חדשה שהם עשויים ליהנות ממנה. נוסף על כך, לסיווג ז'אנר במוזיקה יש שימושים רבים בתעשיה (כגון הפקה מוזיקלית, המלצת מוזיקה, חיפוש מוזיקה ועוד) והצורך לשפר את האלגורתמים של הסיווג תמיד קיים.

לסיכום, פרויקט העוסק בסיווג ז'אנר במוזיקה מספק פתרון רב ובעל ערך לבעיה של סיווג יעיל של מוזיקה לז'אנרים נפרדים, ומאפשר למשתמשים לגלות וליהנות בקלות רבה יותר ממוזיקה התואמת את העדפותיהם.

הצגת פתרונות לבעיה (הפתרונות שנבחנו במסגרת המחקר המקדים)

במסגרת המחקר הבנתי כי הדרך המרכזית והסטנדרטית למיצוי תכונות ולייצוגן על מנת לסווג את הז'אנרים שנמצאים בכל שיר, היא באמצעות MFCC, שבהן נשתמש בפרוייקט זה.

[4] קישור: https://www.kaggle.com/code/vrushaliingle/music-genre-classification-using-cnn/notebook
[5] קישור: https://librosa.org/doc/latest/index.html

רקע תיאורטי

פרויקט זה עוסק בעולמות הפיזיקה והמוזיקה בפרט, לכן יש צורך לדעת ידע תאורטי על מושגים הנוגעים בנושא תורת הקול, למידת מכונה וסיווג ז'אנרים על מנת להבין את הפרוייקט לעומק:

כיצד נוצר גל קול?

גלי קול (sound waves) נוצרים כתוצאה מרטט של משהו. כשמשהו רוטט, הוא מייצר גלי קול באוויר ואז יש צליל. אנשים אוהבים לדמות את גלי הקול לאדוות, גלים זעירים, שנוצרים בבריכה כשמשליכים לתוכה אבן.

ומבחינה מדעית - גלי הקול הם תנודות מחזוריות בלחץ האוויר. התנודות הללו דוחפות את המולקולות של האוויר ואלו זזות הלוך וחזור, ממצב של יציבות ובחזרה, שוב ושוב ושוב -כך נוצר הצליל. המולקולות מתפשטות באוויר ויוצרות גלים - גלי קול. ככל שהתנודות הללו יהיו מהירות יותר, יהיה צליל גבוה יותר, ככל שהתנודות יהיו חזקות יותר - תגדל העוצמה של הצליל שנוצר מגלי הקול הללו.

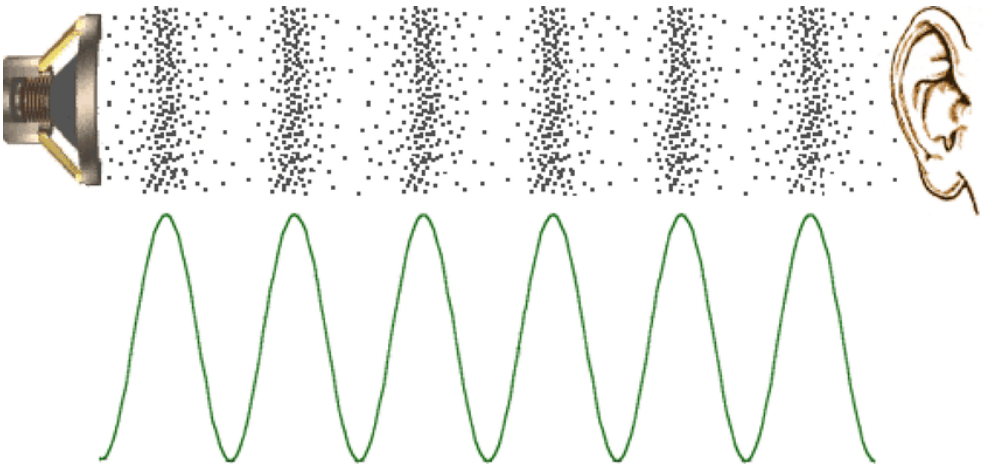

איור:התפשטות גל קול ממקור קול לאוזן האדם[6]

[6] קישור: https://www.researchgate.net/figure/Propagation-of-sound-wave-from-sound-source-to-ear_fig7_330560014

מהי משרעת(אמפליטודה)?

משרעת במוזיקה מתייחסת לעוצמתו או לגודלו של גל קול, שקובע את עוצמת הקול או העוצמה של צליל. בהקשר של מוזיקה, משרעת נמדדת בדרך כלל בדציבלים (dB) ויכולה לנוע בין צלילים שקטים מאוד עם משרעת נמוכה לצלילים חזקים מאוד עם משרעת גבוהה.

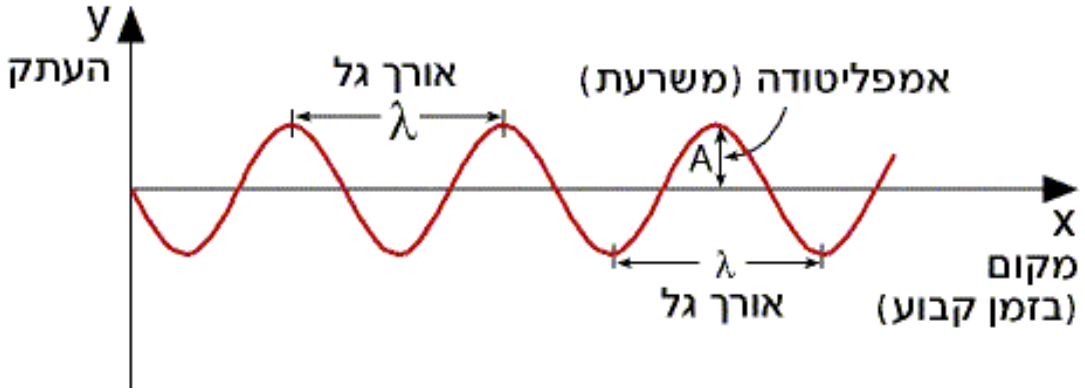

גרף המתאר ההעתק של הגל, כפונקציה של המקום במרחב[7]

מה זה **Sample rate**? (תדירות הדגימה)

קצב הדגימה מתייחס למספר הדגימות של אות רציף שנלקחות בשנייה על מנת לייצג את האות בצורה דיגיטלית. קצב הדגימה מבוטא בהרץ (Hz), שהוא מספר הדגימות בשנייה. ככל שתדירות הדגימה תהיה גבוהה יותר, כך הצליל יהיה קרוב יותר למקור.

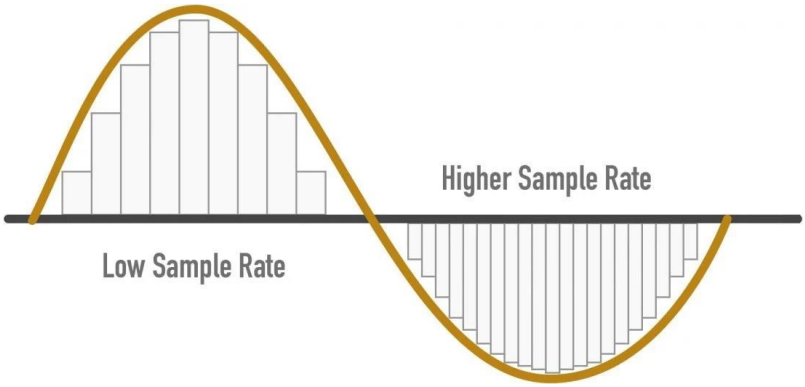

איור: ההבדל בין קצב דגימה נמוך לקצב דגימה גבוה[8]

מה זה מונו?

מונו היא שיטת עיבוד צלילים בעלת ערוץ אחד בלבד. קטע צליל מוגדר כ'מונו' כאשר מקור הצליל (כפי שהוקלט על ידי מיקרופון, למשל) הוא בודד. גם אם קיימים מספר מיקרופונים בעת ההקלטה, ובסופו של התהליך כל הערוצים מתאחדים אל תוך ערוץ אחד - ההקלטה הסופית נחשבת כהקלטת 'מונו' - כלומר, כאשר קול נמצא בערוץ אחד. לדוגמא, כשנשמע מוזיקה באוזניות (שמכילות 2 צדדים, ערוצים - ימין ושמאל) או במספר רמקולים (עם 2 או יותר ערוצים), הקול ישתכפל בשני הצדדים ולא

[7] קישור: https://stwww1.weizmann.ac.il/communication/?page_id=529
[8] קישור: https://www.headphonesty.com/2019/07/sample-rate-bit-depth-bit-rate/

יהיה שלב שבו נשמע רק בצד אחד לדוגמא קטע מוזיקה ובצד השני קטע אחר(שזהו למעשה סטריאו).

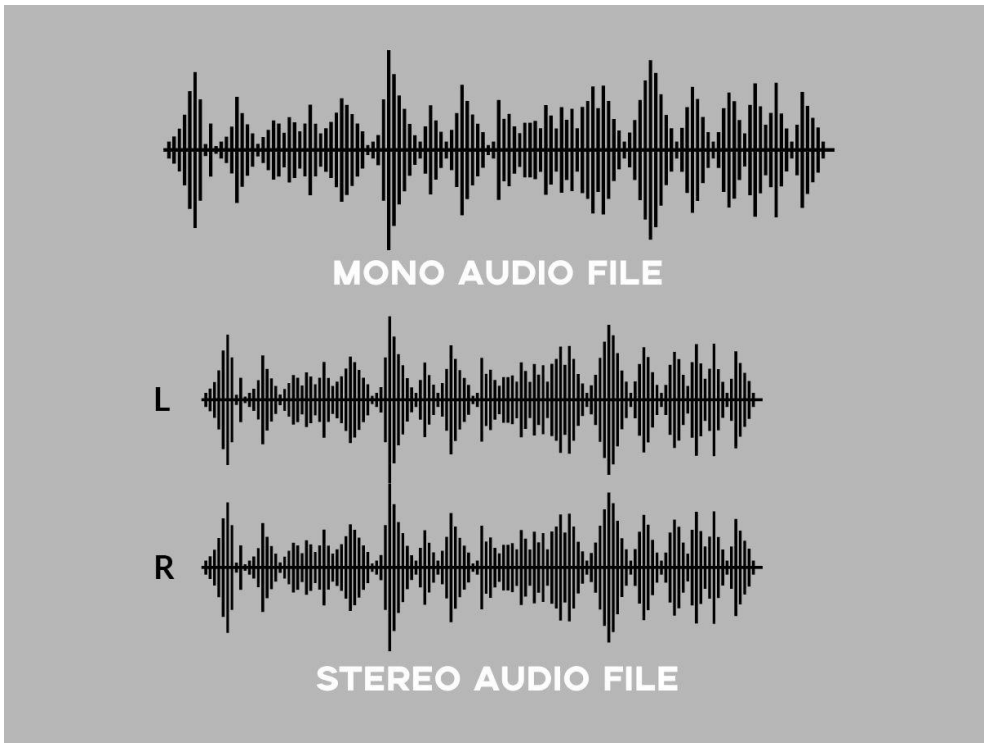

תרשים השוואה בין קובץ מונו לעומת קובץ סטריאו[9]

כפי שניתן לראות באיור, במצב Mono יהיה לנו חלק אחד שמייצג את כל השיר, לעומת זאת ב-Stereo האודיו יהיה מחולק לצד ימין ולצד שמאל.

מהו waveform / waveplot?

waveplot מציגה את משרעת (אמפליטודה) של אות השמע לאורך זמן, כאשר ציר ה-x מייצג זמן, וציר ה-y מייצג משרעת (שמייצגת את העוצמה). ניתן להשתמש ב-waveplot כדי להמחיש את המבנה והמאפיינים הבסיסיים של אות אודיו, כולל תוכן התדר שלו, משך הזמן והצורה הכללית שלו.

ערכי גלים מנורמלים בדרך כלל בין 1 ל-1- מכיוון שגלי קול מיוצגים כתנודות בלחץ האוויר, ויכולים להיות חיוביים או שליליים. הלחץ החיובי המרבי מיוצג כ-1, והלחץ השלילי המרבי מיוצג כ-1-. לכן, כל ערך בין 1 ל-1- מייצג שינוי לחץ האוויר באופן פרופורציונלי ל-0. הערך של 0 מייצג מצב ללא שינוי לחץ.

[9] קישור: https://www.headphonesty.com/2022/01/what-is-the-difference-between-mono-and-stereo/

בעזרת השיטה הזו ניתן להשוות בין צורות גל שונות בקלות יותר, מכיוון שאנו משנים את צורות הגל לאותו טווח של ערכים.

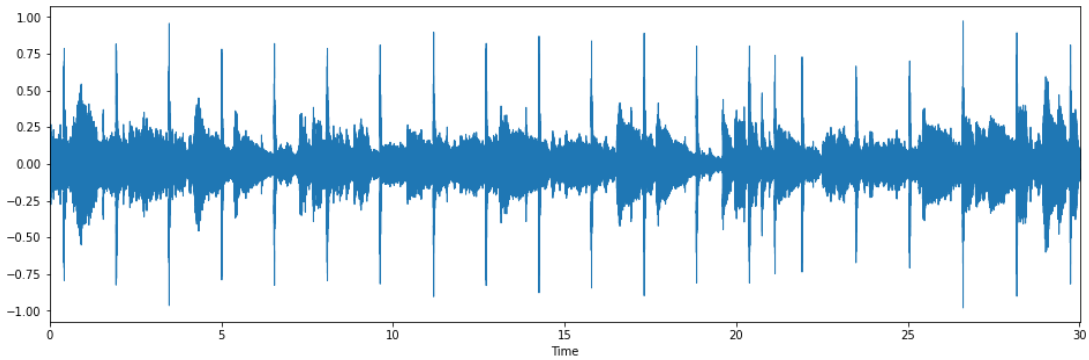

תרשים waveplot שיצרתי בעזרת ספרית Librosa

מהי ספקטוגרמה?

ספקטרוגרמה בהגדרתה, היא ייצוג חזותי של ספקטרום התדרים של האות (קול) והשתנותו עם הזמן. כלומר, ספקטוגרמה היא ייצוג חזותי של 3 מימדים - זמן, תדירות הקול ועוצמתו.

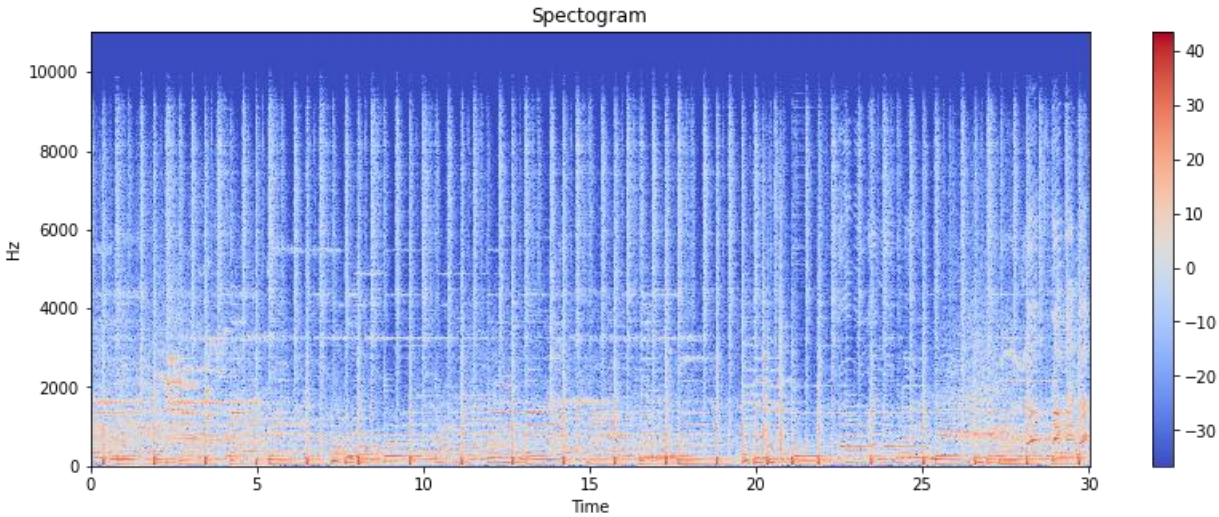

ספקטוגרמה שבניתי בעזרת ספריית Librosa

כפי שניתן לראות בגרף, יש כאן 3 מימדים - הזמן בציר האופקי, התדר בציר האנכי, והמקרא מצד ימין מראה כיצד הצבע משתנה עם העוצמה.

מהי מל ספקטוגרמה? ואיך היא שונה מן ספקטוגרמה (+ מהו סולם מל)

ראשית, קצת על סולם מל - סולם מל הוא סולם המבוסס על הדרך שבה בני אדם תופסים שמיעתית את גובה הצליל. בסולם מל, בניגוד לסולם הרץ הסטנדרטי (שעולה באופן לינארי).

כפי שניתן לראות באיור שנמצא למטה, אנו תופסים את הזמן באופן שאינו לינארי, וככל שהתדירות עולה כך השינוי פחות "נתפס" בשמיעה.

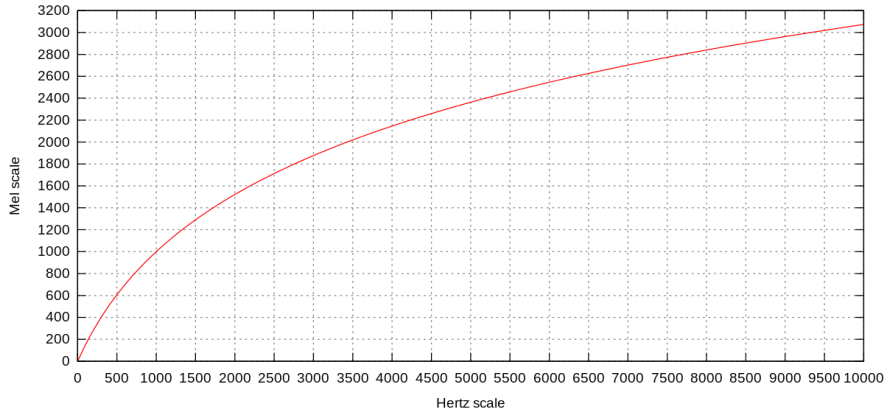

גרף המראה את היחס בגובה בין סולם מל לסולם הרץ סטנדרטי[10]

לצורך המחשה, הגרף (הנמצא למעלה) מראה את היחס בגובה של סולם מל בציר האנכי, וסולם הרץ סטנדרטי בציר האופקי.

מל ספקטוגרמה, בדומה לספקטוגרמה מייצגת 3 מימדים - זמן תדירות הקול ועוצמתו, אך במקרה של מל ספקטוגרמה מימד תדירות הקול מיוחס באמצעות סולם מל - כלומר, בדומה לאיך שאוזן האדם שומעת. בספקטוגרמה נשתמש כאשר לכל התדרים יש "חשיבות" שווה. לעומת זאת, במל ספקטוגרמה נשתמש בייחודיות שלה כאשר היא תתאים ליישומים שבהם אנו ננסה להדגים את הדרך בה האוזן האנושית תתפוס את הצליל/התדר, ולכן לתדרים נמוכים יותר תהינה יותר "חשיבות" מתדרים גבוהים יותר.

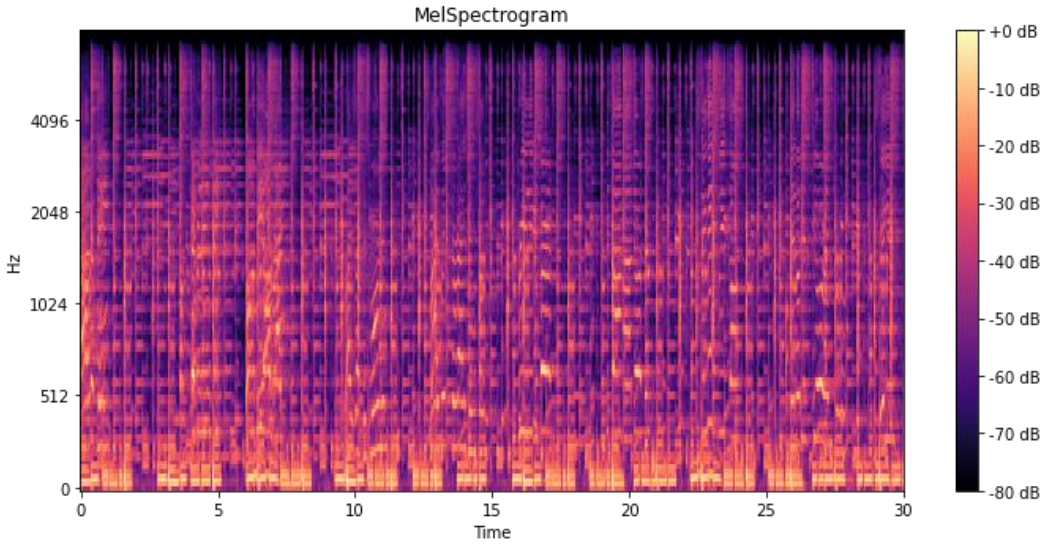

מל ספקטוגרמה שבניתי באמצעות Librosa

[10] קישור: https://he.wikipedia.org/wiki/%D7%A1%D7%95%D7%9C%D7%9D_%D7%9E%D7%9C

מהו **MFCC**? איך הוא מחושב ומה הוא מבטא?

MFCC ראשי תיבות של Mel Frequency Cepstral Coefficients. זוהי דרך לייצג את המאפיינים הספקטרליים של אות אודיו, שהוא התפלגות האנרגיה של האות על פני תדרים שונים (ובכך לראות תדרים יותר/פחות דומיננטיים), ומיוצג בסולם מל.

MFCCs נמצאים בשימוש נרחב בעיבוד וניתוח אותות אודיו, במיוחד עבור זיהוי דיבור, זיהוי דובר ושליפה של מידע מהמוזיקה/קטע שיר. הם מחושבים באמצעות סדרה של טרנספורמציות מתמטיות הממירות אות אודיו של תחום זמן לייצוג של תחום תדר, ולאחר מכן לסט קומפקטי של מקדמים הלוכדים את התכונות החשובות ביותר של האות.

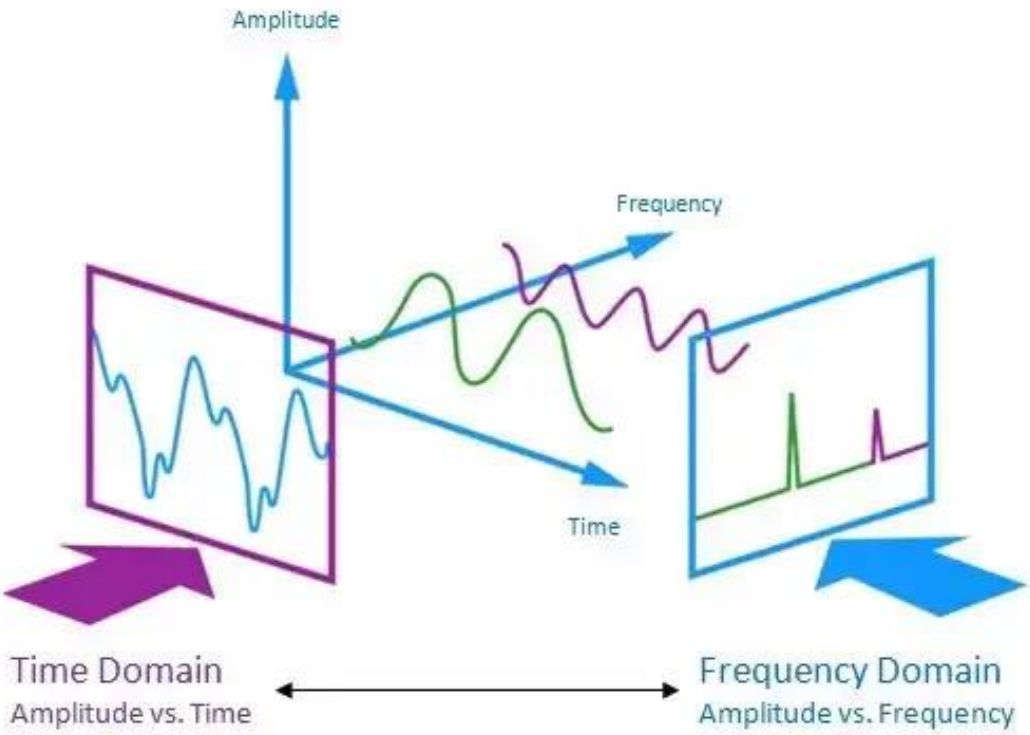

אות בתחום זמן ואות בתחום תדר[11]

באיור למעלה ישנו ייצוג ויזואלי של ייצוג זמן-עוצמה לעומת ייצוג עוצמה-תדר ושל איך נראית המרה מייצוג תחום זמן לתחום תדר - ככל שהתדר יותר חזק, כך הגובה יהיה גבוה יותר.

במילים פשוטות - MFCCs הם דרך להמיר גלי קול לקבוצה של מספרים המייצגים את המאפיינים הייחודיים של הצליל, כגון גובה הצליל, הגוון והוליום שלו (והכל ביחס לשמיעת האדם, כלומר בסולם

[11] קישור: https://www.kindpng.com/imgv/hwiooiT_file-mel-hz-plot-svg-mel-scale-hd/

מל). לאחר מכן ניתן להשתמש במקדמים אלה כדי לסווג או להשוות צלילים שונים, כגון זיהוי מילים או זיהוי ז'אנר מוזיקלי.

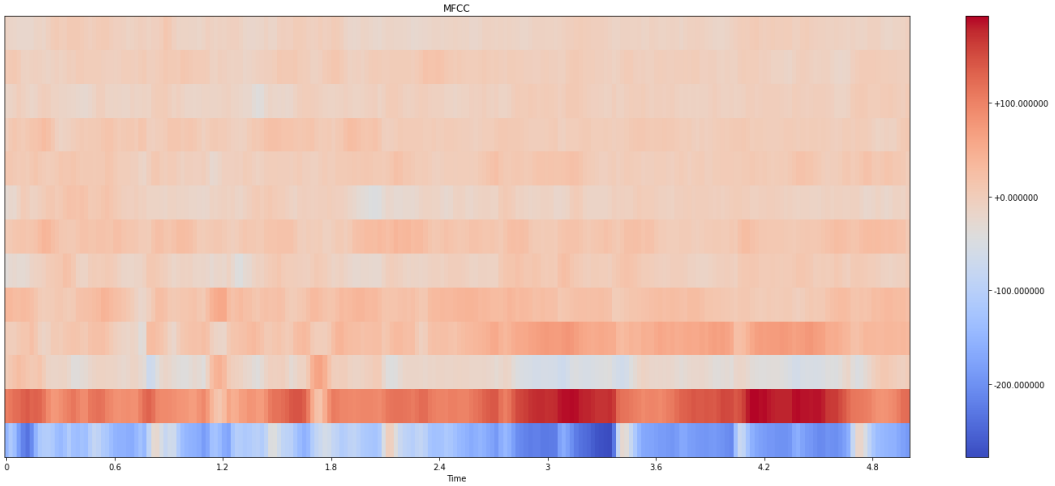

הצגת ויזואלית של MFCC לאורך זמן, באמצעות גרף שיצרתי בעזרת ספריית Librosa

הגרף למעלה, מדגים הצגה ויזואלית של MFCC לאורך זמן. המימד האופקי - X מייצג את הזמן, והמימד האנכי - Y מייצג את קבוצת המקדמים שעליהם דיברנו, כל מלבן מייצג מקדם מסדר גבוה או נמוך יותר. המקדמים מסדר נמוך נוטים לייצג את הצורה הכוללת של המעטפת הספקטרלית (כלומר, האנרגיה/הדומיננטיות של תדרים שונים מתוך ספקטרום התדרים), בעוד שהמקדמים מסדר גבוה יותר לוכדים מידע מפורט יותר על המעטפת הספקטרלית.

לדוגמה, מקדם ה-MFCC הראשון מכונה לעתים קרובות "הממוצע הספסטרלי" (Cepstral mean) ומייצג את האנרגיה הממוצעת בכל פסי התדר. מקדם MFCC השני מייצג את השונות של התפלגות האנרגיה, שניתן לחשוב עליה כמדד ל"פיזור" האנרגיה על פני פסי התדרים השונים. מקדמים מסדר גבוה יותר לוכדים פרטים עדינים יותר ויותר על חלוקת האנרגיה.

באופן כללי, מקדמי הסדר הנמוך חשובים יותר עבור משימות כגון זיהוי דובר או זיהוי דיבור, כאשר הצורה הכוללת של המעטפת הספקטרלית היא תכונה מרכזית להבחנה בין דוברים או מילים שונות. מקדמי הסדר הגבוה יותר עשויים להיות שימושיים יותר עבור משימות כגון סיווג ז'אנר מוזיקה, כאשר מידע מפורט יותר על המעטפת הספקטרלית יכול להיות אינפורמטיבי להבחנה בין ז'אנרים שונים של מוזיקה.

הצבע של כל מלבן בגרף מייצג את הגודל או החוזק של המקדם המתאים במסגרת זמן מסוימת, טווח הצבעים המשמש בחלקות MFCC הוא בדרך כלל נמצא בטווח מכחול (בעוצמה נמוכה) לאדום (בעוצמה גבוהה), אם כי ניתן להשתמש בסכימות צבעים שונים.

נוסף על כך, ככל שאורך המלבן קטן יותר, כך חישבנו יותר מקדמים של הMFCC (כמות המקדמים שבחרנו לכל אורך קטע זמן קטן יותר - X axis), וככל שגובה המלבן קטן יותר, חישבנו את העוצמה של יותר כמות של מקדמים לאורך קטע זמן מסויים (Y axis).

מהי התמרת פוריה?

התמרת פוריה הוא כלי מרכזי בניתוח הרמוניה/מוזיקה שאפשר לתארו כפירוק של פונקציה לרכיבים מחזוריים (סינוסים וקוסינוסים לדוגמא) וביצוע אנליזה מתמטית לפונקציה על ידי ניתוח רכיביה.
שיטה זו פותחה על ידי המתמטיקאי ז'אן-בטיסט ז'וזף פורייה.

מה היא התמרת פוריה מהירה?

התמרה זו בפשטות, היא אלגוריתם יעיל לחישוב התמרת פורייה בדידה וההתמרה ההופכית שלה.
באמצעות התמרה זו, נמיר חלקים מהשיר מתחום זמן לתחום תדר(ראה עמוד 12), נוסיף חישובים נוספים ונגיע ל.MFCCs

מה זה אומר קובץ אודיו של 16 **Bit**?

קובץ שמע של 16 סיביות הוא סוג של קובץ שמע דיגיטלי המאחסן סאונד באמצעות 16 סיביות של מידע עבור כל דגימה של הסאונד (Sample). מספר הביטים קובע את כמות הפרטים והדיוק שניתן ללכוד בצליל, כאשר עומקי סיביות גבוהים יותר מאפשרים בדרך כלל איכות ואמינות טובים יותר.
קובץ אודיו של 16 סיביות משמש בדרך כלל עבור שמע באיכות שנקראת איכות CD, שהוא הסטנדרט עבור רוב התקני השמעת מוזיקה ואודיו.

מה זה קונבלוציה **?convolution /**

שכבת קונבולוציה היא אבן הבניין המרכזית של CNN.
אנו יכולים לחשוב על תמונת הקלט כעל מטריצה, שבה כל ערך מייצג כל פיקסל, וערך בין 0 ל-255 המייצג את עוצמת הבהירות. כאשר מעבדים תמונה צבעונית, ולוקחים בחשבון את הצבעים, יהיו 3 ערוצים, מסוג RGB. במקרה שלי אני משתמש במימד אחד(שניתן להשוות לתמונה בשחור לבן - ערוץ 1), וערכי המספרים תלויים בערכי הMFCCs.

אחת הדרכים להבין את פעולת הקונבולוציה היא לדמיין הצבת Filter הקונבולוציה בחלק העליון של תמונת הקלט, הממוקם בצורה כך שה-Kernel והתמונה בפינות השמאליות העליונות חופפות, ולאחר מכן הכפלת הערכים של מטריצת תמונת הקלט בהתאם, עם הערכים המתאימים ב-Filter הקונבולוציה (כפל מסוג dot product).

כל הערכים המוכפלים מתווספים יחדיו וכתוצאה מכך נוצר סקלר יחיד, אשר ממוקם במיקום הראשון של מטריצת תוצאה.

לאחר מכן, ה-Kernel יזוז X פיקסלים ימינה, כאשר X מייצג את אורך הצעד (Stride) שאנו יכולים לקבוע, תהליך החישוב חוזר על עצמו, והתוצאה נרשמת בחלק השני של מטריצת התוצאה. לאחר שהסתיימה שורה, ה-Kernel יזוז X פיקסלים מטה בהתאם עד שיסתיים התהליך.
לבסוף, יצא פלט המכונה Feature map.

ככל שגודל ה-kernals גדול יותר ככה יהיה זיהוי מדוייק יותר אבל השכבה תדרוש יותר כוח חישוב והמודל ירוץ לאט יותר.

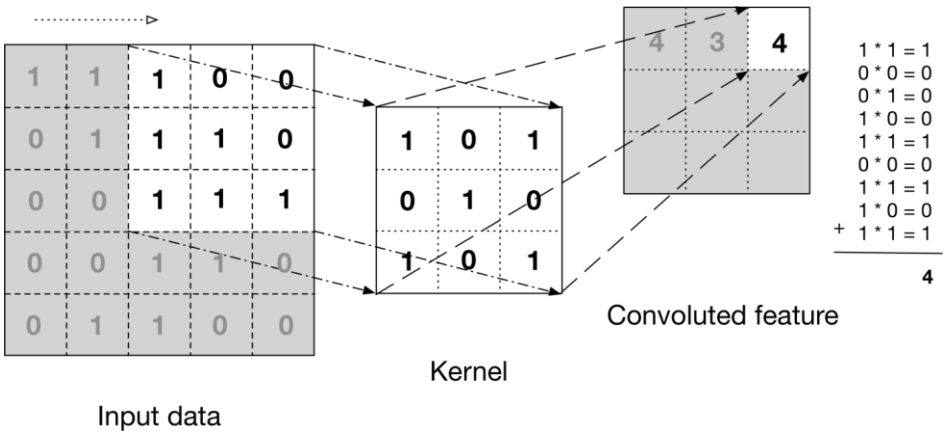

איור: דוגמא לפעולת קונבולוציה[12]

מה עושה **max pooling**?

max pooling דומה לתהליך הקונבולוציה בכך שישנו גודל Kernel מסויים שנקבע, ויש אפשרות לבחור Stride מסויים. הפונקציה תקח מתוך ה-Kernel את המספר המקסימלי שנמצא בקלט שקיבלנו ותוציא אותו. היא תעשה את התהליך ותוציא פלט עם המספרים המקסימיליים בכל איזור שחישבה.

[12] קישור: https://www.davidsbatista.net/blog/2018/03/31/SentenceClassificationConvNets/

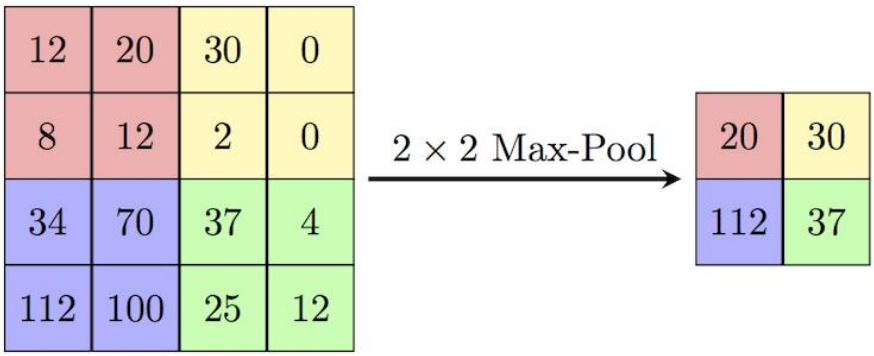

איור: דוגמא לפעולת max pooling[13]

המשמעות של global average pooling?

global average pooling היא שיטה המשמשת למעבר מרשת CNN, לרשת DNN (תהליך שיטוח).

הקלט מורכב משלושה מימדים - אורך, רוחב ועומק - feature map. בשיטת global average pooling ייקח כל feature map וייחשב את הממוצע שלו, לבסוף יישאר מערך (1,1,X) כאשר X מייצג ממוצע מכל feature map.

מהי פונקצית שגיאה sparse categorical cross-entropy?

פונקצית שגיאה, זו פונקציה המשמשת למדידה עד כמה מודל מסויים בלמידת מכונה מתפקד במשימה נתונה.

במהלך האימון, המודל מבצע תחזיות על קבוצה של קלטים, ומשווה אותן לסיווג בפועל(כלומר,משווה לדוגמא חיזוי ז'אנר שיר לעומת הז'אנר האמיתי שלו), פונקציית ההפסד מחשבת את ההפרש בין החיזויים, לסיווג בפועל, ומחזירה ערך בודד המייצג עד כמה תחזיות המודל היו "שגויות".

בזמן האימון, מטרתנו היא למזער כמה שניתן את הערך של פונקצת ההפסד - בכך, יהפכו התחזיות ליותר מדוייקות.

[13] קישור: https://computersciencewiki.org/index.php/File:MaxpoolSample2.png

מבנה / ארכיטקטורה של הפרויקט

מימוש:

על מנת לממש את הפרוייקט, השתמשתי במספר ספריות, ביניהן המרכזיות -

- **TensorFlow** :TensorFlowהיא ספריית למידת מכונה בקוד פתוח שפותחה על ידי גוגל. זוהי אחת הספריות הנפוצות ביותר לבניית והדרכה של מודלים של למידה עמוקה, והיא מספקת מגוון רחב של כלים וממשקי API לעבודה עם רשתות עצביות (Neural networks). נשתמש בה בצורה רחבה בשלבי האימון.
- **Librosa** :Librosaהיא ספריית Python לניתוח ועיבוד אותות אודיו. הוא מספק מגוון כלים לטעינת קבצי אודיו, חילוץ תכונות מקבצי האודיו (כגון MFCCs), ותפעול הנתונים המתקבלים. Librosa היא ספריה מרכזית בה נשתמש על מנת להכין את הנתונים לשלב האימון, וגם בחיזוי.
- **Gradio** :Gradioהיא ספריית Python המספקת דרך קלה לבנות ממשקי משתמש מבוססי אינטרנט (web-based UI) עבור מודלים של למידת מכונה. עם Gradio, אפשר ליצור במהירות ממשקים אינטראקטיביים המאפשרים למשתמשים להזין נתונים, להריץ מודל על נתונים אלה ולהציג את התוצאות. בGradio נשתמש בתהליך היישום.
- **Resampy** :Resampyהיא ספריית Python לדגימה מחדש של אותות אודיו. הוא מספק מגוון כלים לשינוי קצב הדגימה של אות אודיו, שיכול להיות שימושי לעיבוד מוקדם של נתוני אודיו לפני הזנתם למודל למידת מכונה. בResampy נשתמש בתהליך היישום.

שלב איסוף הכנה וניתוח הנתונים

בשלב איסוף הנתונים השתמשיתי ב-dataset של ז'אנרים שונים במוזיקה ושמו .**GTZAN** בשנת 2002, G. Tzanetakis ו-P. Cook חוקרים בתחום מדעי המחשב והמוזיקה, הציגו את המאמר הידוע שלהם על סיווג ז'אנר, "סיווג ז'אנר מוזיקלי של אותות אודיו", שפורסם ב- IEEE Transactions on Audio and Speech Processing[14]

דאטא סט זה, מכיל 1,000 דגימות שירים המשתייכות לסך של 10 ז'אנרים מוזיקליים רגילים. הדגימות מסווגות לבלוז, קלאסי, קאנטרי, דיסקו, היפ הופ, ג'אז, מטאל, פופ, רגאיי ורוק. כל ז'אנר מכיל 100 שירים. במערך הנתונים של GTZAN, כל שיר הוא באורך 30 שניות, עם קצב דגימה (Sample rate) של 22,050 הרץ, על מצב מונו, פורמט קובץ Wav וקובצי אודיו של 16 סיביות .

[14] IEEE היא אגודה מקצועית בינלאומית של העוסקים בהנדסת חשמל ואלקטרוניקה, הנדסת מחשבים והנדסת תוכנה.

מערך הנתונים נמצא בשימוש נרחב למחקר סיווג ז'אנר מוזיקה והיווה בסיס למספר רב של מאמרים אקדמיים ותחרויות למידת מכונה, ומערך זה הפך למערך סטנדרטי כמערך נתונים להערכת הביצועים של אלגוריתמים לסיווג ז'אנר מוזיקה.

הקבצים נאספו בשנים 2000-2001 ממגוון מקורות כולל דיסקים אישיים, רדיו, הקלטות מיקרופון, על מנת לייצג מגוון תנאי הקלטה.

תמונה ובה מוצגים אומנים מרכזיים בז'אנר, ולאחריה תמונה המציגה את הסאב ז'אנרים המרכזיים:[15]

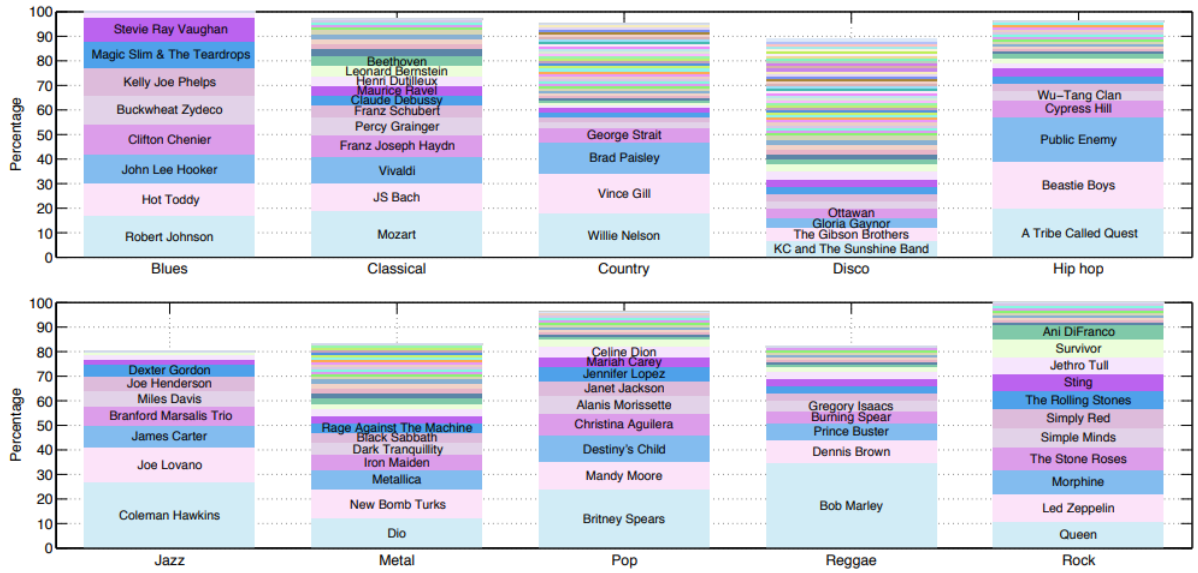

Figure 1: Artist composition of each *GTZAN* category. We do not include unidentified excerpts.

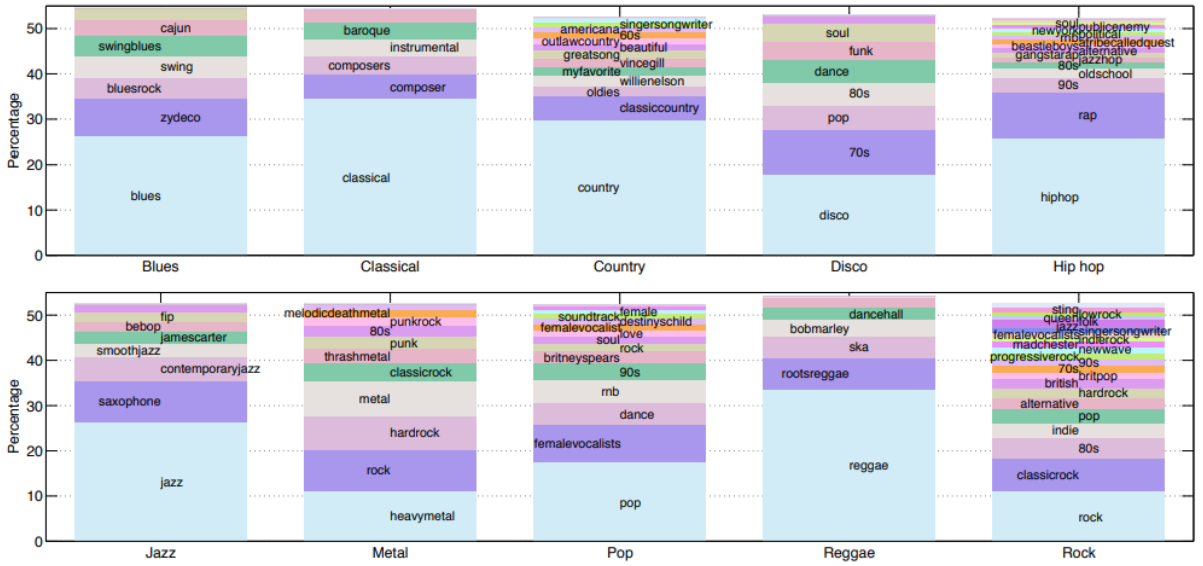

Figure 2: Top tags of each *GTZAN* category. We do not include unidentified excerpts.

[15] קישור: https://arxiv.org/pdf/1306.1461.pdf

להכנת ה-Dataset שאיתו נעבוד ונאמן את המודל היינו צריכים להמיר אותו למבנה מסוג MFCC. בקוד, בנינו מבנה נתונים שיאחסן לנו 3 מרכיבים חשובים - שמות 10 הז'אנרים, מערך מסוג Dictionary אשר מכיל את הז'אנר "האמיתי" של הקטע מהשיר, והMFCC שלו בהתאם.

בתהליך ההכנה: חילקנו את השיר ל-6 מקטעים, בכדי שיהיו יותר נתונים שנוכל להתאמן איתם ושיהיה לנו חישוב MFCC יותר יעיל (דהיינו, 5 שניות לכל מקטע). ביצענו חישוב מתמטי באמצעות התמרת פוריה מהירה על הקטע, ושמנו את כל תגיות השירים (ערך הז'אנר שלהם) וה-MFCC שלהם בהתאמה במבנה הנתונים. סיימנו ושמרנו הכל באמצעות קובץ JSON, מכיוון שמתאים לסוג מבנה הנתונים שבו השתמשנו (פורמט מפתח-ערך) ועל מנת לקבל קובץ אחד קומפקטי שאיתו נעבוד.

בנוסף, לפני הפעלת הפונקציה הממירה ל-MFCC, שמרנו במשתנים את הנתונים שידועים לנו, כגון אורך שיר, קצב דגימה, הנתיב לדאטאסט. ואת הכל נוציא ונשמור בגוגל דרייב כקובץ בפורמט JSON בנתיב שבחרנו.

- במהלך היצירה התעלמתי מהקובץ jazz.00054.wav, מכיוון שהקובץ ככל הנראה אינו נוצר כראוי ולכן מעלה שגיאה כשאנו מנסים לגשת אליו:

“fileError: Error opening '/content/drive/MyDrive/ColabNotebooksNew/PROJECT/ProjectMusic/Data/genres_original/jazz/jazz.00054.wav': File contains data in an unknown format.”

כאשר מתבצעת הפונקציה MFCC, היא לוקחת את כל החלקים (ישנם 1000 שירים, שמחולקים ל-6 חלקים שונים אך נתעלם מקטע שלם, כלומר 6 חלקים).
נוודא שגודל ה-MFCC של המקטע (segment) הוא כראוי. אך, נמצא שישנם שני מקטעים מתוך השירים שה-MFCC שלהם אינו בנוי כראוי והם:

- hiphop.00032.wav בשניות 25-30.
- country.00007.wav בשניות 25-30.

לאחר מכן, תשמור הפונקציה במשתנים X,Y,Z כאשר כל אחד מייצג:

- X - store the mfccs
- Y - Stores the 'real' song type(value from 0-9)
- Z - genres/label names

לאחר מכן, הכל ישמר כקובץ JSON בתוך הגוגל דרייב עם הנתיב שאליו החלטתי שיגיע.
מספר הקטעים שהוכנסו, הוא 5992 מכיוון שהתעלמנו משיר שלם (6 חלקים), ו-2 חלקים נוספים מתוך השירים. הגודל של כל MFCC יהיה (216,13) כלומר יש חישוב של 13 מקדמי MFCC, על כל דגימה, למשך 216 דגימות בקטע, ויהיו סך הכל 5992 מקטעים(Segments) כאלה.

תיאור המודל:
במודל השתמשתי ברשת נוירונים מסוג CNN, מכיוון שהיא מתאימה לסיווג ז'אנר באמצעות MFCCs. הסיבה לכך, שמבנה רשת נוירונים מסוג CNN, יכול ללמוד לזהות דפוסים ותכונות בייצוגי MFCC, מה שהופך אותו ליעיל בחילוץ מידע שימושי לסיווג ז'אנר.

שלב בנייה ואימון המודל:

בניתי מודלים שונים ושיפרתי את המודל:
ראשית, לקחתי את המודל המקורי בו נעזרתי, ואחוזי הדיוק היו 68.95%

לאחר מכן, ניסיתי לשפר ולשנות את המודל ולראות את התוצאות.

- ניסיתי לשנות את אחוזי האימון, שיפור ובדיקה וראיתי שהאחוזים אופטימליים בסביבות (Test set, 10% Validation Set, 80% Training Set 10%).
- לאחר מכן, ניסיתי אופטימייזרים שונים כגון RMSProp, SGD ועוד, אך ראיתי ש-Adam הביא את התוצאות המקסימליות.
- שיניתי את הקצב הלמידה והוספתי פונקציה שתקטין את קצב הלמידה בזמן האימון עצמו - ששיפר את המודל.
- הגדלתי את כמות ה-Epochs והוספתי Earlystopping - שראיתי כי שיפר את תוצאות המודל.
- שיחקתי עם מבנה הקונבולוציה עד כי הגעתי למבנה האופטימלי.

מבנה המודל הסופי:

```
# build network topology
model = keras.Sequential()

model.add(keras.layers.Conv2D(32, (3, 2), activation='relu',input_shape=input_shape,kernel_regularizer=tf.keras.regularizers.L1L2(0.01)))

model.add(keras.layers.BatchNormalization())

model.add(keras.layers.Conv2D(64, (3, 2), activation='relu'))

model.add(keras.layers.MaxPooling2D((3, 2),strides=(2,1)))

model.add(keras.layers.BatchNormalization())

model.add(keras.layers.Conv2D(64, (3, 2), activation='relu'))

model.add(keras.layers.BatchNormalization())

model.add(keras.layers.Conv2D(128, (3, 2), activation='relu'))

model.add(keras.layers.BatchNormalization())

model.add(keras.layers.MaxPooling2D((3, 2)))
# flatten output and feed it into dense layer
model.add(keras.layers.GlobalAveragePooling2D())
# output layer
model.add(keras.layers.Dropout(0.2))

model.add(keras.layers.Dense(10, activation='softmax'))

return model
```

המודל נבנה באמצעות ספריית Keras שנמצאת בספריות הפתוחות של Tensorflow. מטרת מודל זה היא לסווג נתוני קלט לאחת מעשר קטגוריות אפשריות באמצעות למידה מפוקחת.

צורת הקלט של הנתונים היא (216, 13, 1), מה שאומר שלנתוני הקלט יש 216 שורות, 13 עמודות וערוץ יחיד.

מבנה ה- **CNN**-

1. שכבת קונבולוציה שמקבלת כגודל את הקלט, עם 32 מסננים בגודל (3,2) (הסיבה לגודל ה"מלבני" הוא גודל הקלט שאנו מקבלים) עם פונקציית הפעלה של פונקצית ReLU ורגולריזציה-2L1L בגודל (0.01)
2. שכבת BatchNormalization מנרמלת את השכבה הקודמת בכל Batch.
3. שכבת קונבולוציה שנייה עם 64 מסננים בגודל (3,2) עם פונקצית הפעלה של Relu

4. שכבת MaxPooling2D עם גודל (3, 2) וStride בגודל (2, 1), מה שמקטין את הממדים המרחביים של הפלט.
5. שכבת נוספת של BatchNormalization מנרמלת את השכבה הקודמת בכל Batch.
6. שכבת קונבולוציה שלישית עם 64 מסננים בגודל (3,2) עם פונקצית הפעלה של Relu
7. שכבת נוספת של BatchNormalization מנרמלת את השכבה הקודמת בכל Batch.
8. שכבת קונבולוציה רביעית עם 128 מסננים בגודל (3,2) עם פונקצית הפעלה של Relu
9. שכבת נוספת של BatchNormalization מנרמלת את השכבה הקודמת בכל Batch.
10. שכבת MaxPooling2D עם גודל (3, 2), מה שמקטין את הממדים המרחביים של הפלט.
11. שכבת GlobalAveragePooling2D משטחת את הפלט ומזינה אותו לשכבה צפופה(DNN).

מבנה ה**DNN-**

1. מתווספת שכבת Dropout בשיעור של 0.2 למניעת התאמת יתר (Overfitting).
2. לבסוף, שכבה צפופה עם 10 נוירונים ופונקציית אקטיבציה של softmax מתווספת כשכבת הפלט כדי ליצור את הניבויים שבמחלקה.

```
# compile model
optimizer = keras.optimizers.Adam(learning_rate=0.00015)
model.compile(optimizer=optimizer,
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])

model.summary()

earlystopping = tf.keras.callbacks.EarlyStopping(monitor='val_loss',patience=8,verbose=1) #patience=stop after 8 epochs without improvement(on vall loss)

reduceLR = tf.keras.callbacks.ReduceLROnPlateau(monitor='val_loss', factor=0.9,patience=4, verbose=1, mode='auto')

# train model
history = model.fit(X_train, y_train, validation_data=(X_validation, y_validation), batch_size=64, epochs=150, verbose=1,callbacks=[earlystopping, reduceLR])

duration = datetime.now()

# evaluate model on test set
test_loss, test_acc = model.evaluate(X_test, y_test, verbose=2)
print('\nTest accuracy:', test_acc)
print("Training completed in time:", duration)
```

משתמשים באופטימייזר Adam, נגדיר את קצב הלמידה עבור האופטימיזציה ל-0.00015.
נבנה את המודל ונשתמש בפונקציית loss (שגיאה) בזמן האימון של sparse categorical cross-entropy, ונשתמש במדד הערכה באמצעות הדיוק.

נשתמש ב-EarlyStopping על מנת במקרה ואין שיפור באחוזי המודל (באמצעות סט val) לאחר 8 אפוקים.

נשתמש ב-ReduceLROnPlateau, במידה ונראה לאחר 4 אפוקים כי אין שיפור, נקטין את ערך הlearning rate (קצב הלמידה)

נבנה את המודל ונשתמש בפונקצית model.fit.

- batch size = 64
- epochs = 150

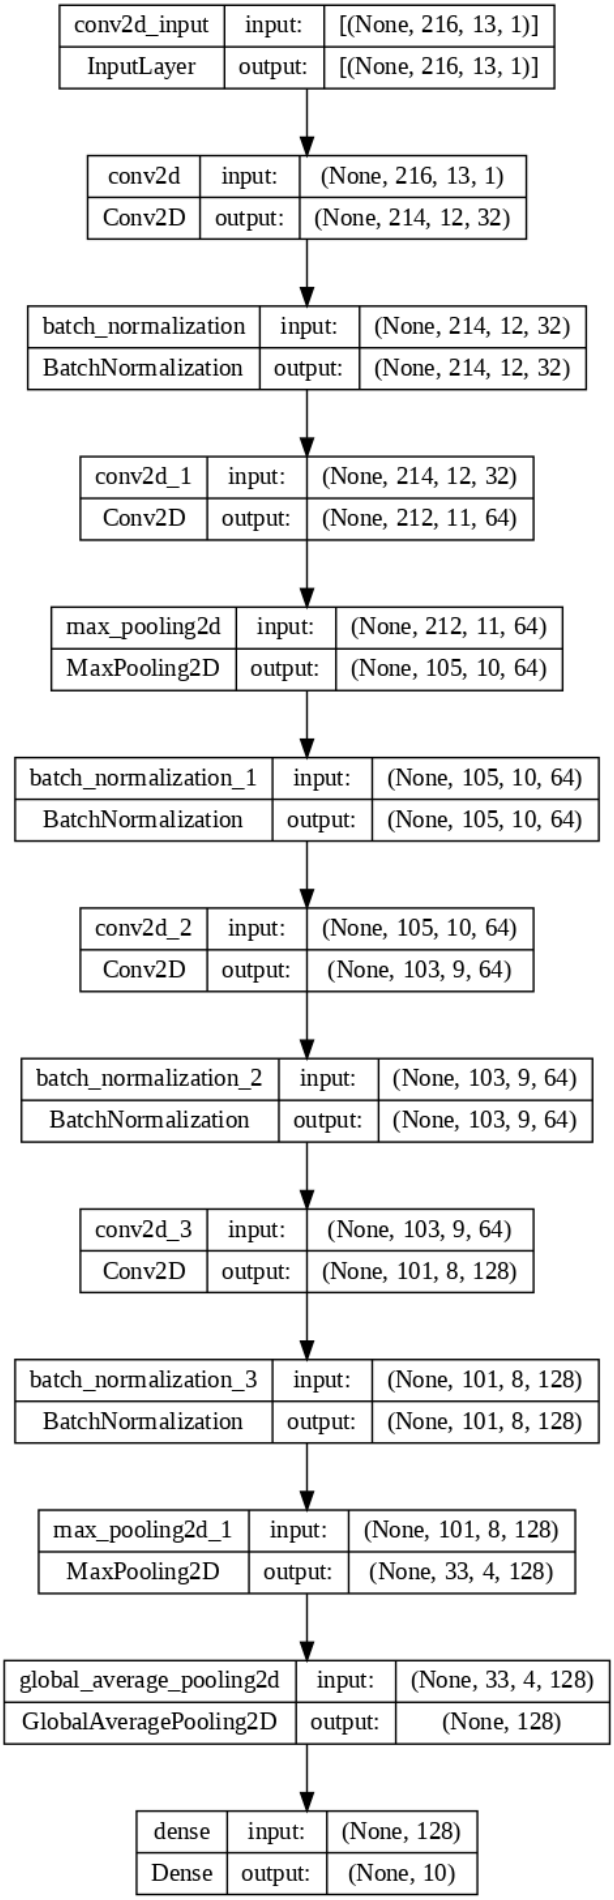
conv2d_input
InputLayer
input:
output:
[(None, 216, 13, 1)]
[(None, 216, 13, 1)]
conv2d
Conv2D
input:
output:
(None, 216, 13, 1)
(None, 214, 12, 32)
batch_normalization
BatchNormalization
input:
output:
(None, 214, 12, 32)
(None, 214, 12, 32)
conv2d_1
Conv2D
input:
output:
(None, 214, 12, 32)
(None, 212, 11, 64)
max_pooling2d
MaxPooling2D
input:
output:
(None, 212, 11, 64)
(None, 105, 10, 64)
batch_normalization_1
BatchNormalization
input:
output:
(None, 105, 10, 64)
(None, 105, 10, 64)
conv2d_2
Conv2D
input:
output:
(None, 105, 10, 64)
(None, 103, 9, 64)
batch_normalization_2
BatchNormalization
input:
output:
(None, 103, 9, 64)
(None, 103, 9, 64)
conv2d_3
Conv2D
input:
output:
(None, 103, 9, 64)
(None, 101, 8, 128)
batch_normalization_3
BatchNormalization
input:
output:
(None, 101, 8, 128)
(None, 101, 8, 128)
max_pooling2d_1
MaxPooling2D
input:
output:
(None, 101, 8, 128)
(None, 33, 4, 128)
global_average_pooling2d
GlobalAveragePooling2D
input:
output:
(None, 33, 4, 128)
(None, 128)
dense
Dense
input:
output:
(None, 128)
(None, 10)

```
Model: "sequential_9"
_________________________________________________________________
 Layer (type)                Output Shape              Param #
=================================================================
 conv2d_24 (Conv2D)          (None, 214, 12, 32)       224

 batch_normalization_24 (Bat  (None, 214, 12, 32)      128
 chNormalization)

 conv2d_25 (Conv2D)          (None, 212, 11, 64)       12352

 max_pooling2d_12 (MaxPoolin  (None, 105, 10, 64)      0
 g2D)

 batch_normalization_25 (Bat  (None, 105, 10, 64)      256
 chNormalization)

 conv2d_26 (Conv2D)          (None, 103, 9, 64)        24640

 batch_normalization_26 (Bat  (None, 103, 9, 64)       256
 chNormalization)

 conv2d_27 (Conv2D)          (None, 101, 8, 128)       49280

 batch_normalization_27 (Bat  (None, 101, 8, 128)      512
 chNormalization)

 max_pooling2d_13 (MaxPoolin  (None, 33, 4, 128)       0
 g2D)

 global_average_pooling2d_6   (None, 128)              0
 (GlobalAveragePooling2D)

 dropout_3 (Dropout)         (None, 128)               0

 dense_4 (Dense)             (None, 10)                1290

=================================================================
Total params: 88,938
Trainable params: 88,362
Non-trainable params: 576
_________________________________________________________________
```

תוצאות והערכת ביצועים:

מודל סופי:

- אחוזי דיוק:91.166%
- Optimizer: Adam
- Learning rate:0.00015 (עם תהליך הפחתה במהלך הלמידה)
- batch size:64
- epoch size: 150 (עם EarlyStopping)
- טבלאות ונתונים נוספים -

תיעוד גרף של אחוזי הדיוק וה-Loss באימון, ובמבחן (ניתן לראות שיש מעט אוברפיטינג שניסיתי להתמודד איתו במהלך הלמידה והקטנתי אותו בתהליך)

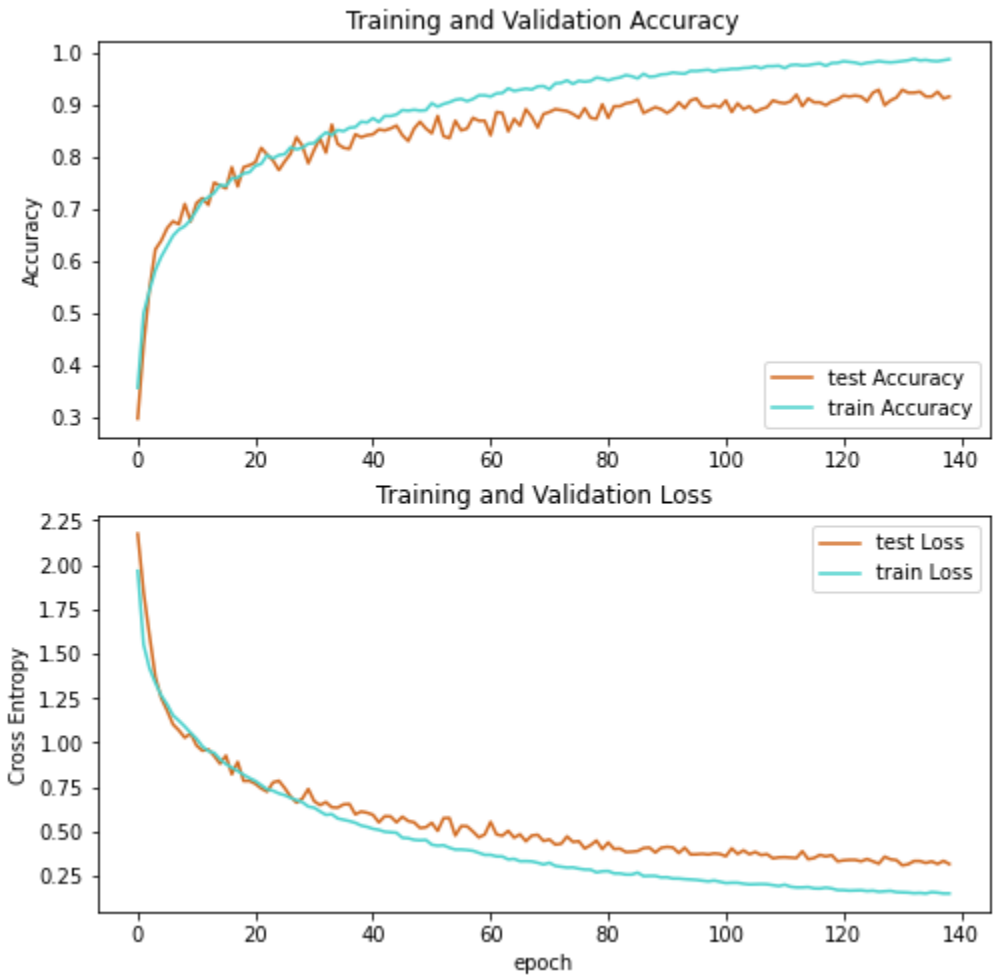

Classification report:

	precision	recall	f1-score	support
0	0.9737	0.9867	0.9801	75
1	0.9861	1.0000	0.9930	71
2	1.0000	0.9701	0.9848	67
3	0.9811	1.0000	0.9905	52
4	0.9672	0.9672	0.9672	61
5	0.9804	0.9615	0.9709	52
6	0.9804	0.9615	0.9709	52
7	0.9796	0.9796	0.9796	49
8	0.9821	0.9821	0.9821	56
9	0.9848	1.0000	0.9924	65
accuracy			0.9817	600
macro avg	0.9816	0.9809	0.9812	600
weighted avg	0.9817	0.9817	0.9816	600

Confusion Matrix:

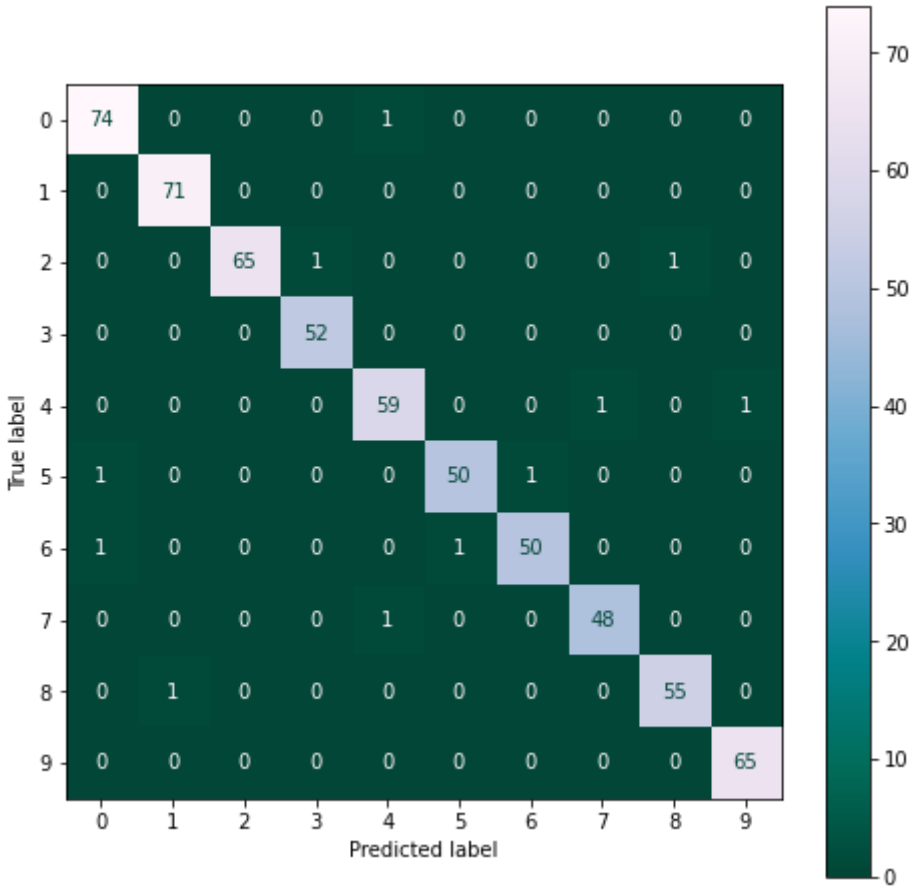

שלב היישום

את היישום כתבתי בעזרת הספריה Gradio, שכפי שפורט עליה היא מאפשרת לכתוב ממשק משתמש נוח ופשוט, ומשומשת בעיקר לבניית Web עם פרוייקטים של למידת מכונה.
במהלך היישום, היישום מקבל קובץ שיר, הוא ממיר אותו לקובץ מסוג Wav (כך שיתאים להמרת הMFCC), נשנה את הSample rate בכך שיהיה מתאים לפונקציה - שנמיר ל-MFCC. לאחר מכן, נשתמש בפונקציה Predict, ננבא הרבה חלקים מהשיר ונציג חיזויים בעזרת מספר עשרוני (של אחוז של חיזוי של הז'אנר הספציפי מתוך כל החיזויים של קטעי השיר) שאותו נחזיר, ביחד עם זמן האימון שלקח, Waveform וMelSpectogram.

מדריך שימוש ביישום:

ראשית נגיע לאתר הזה:

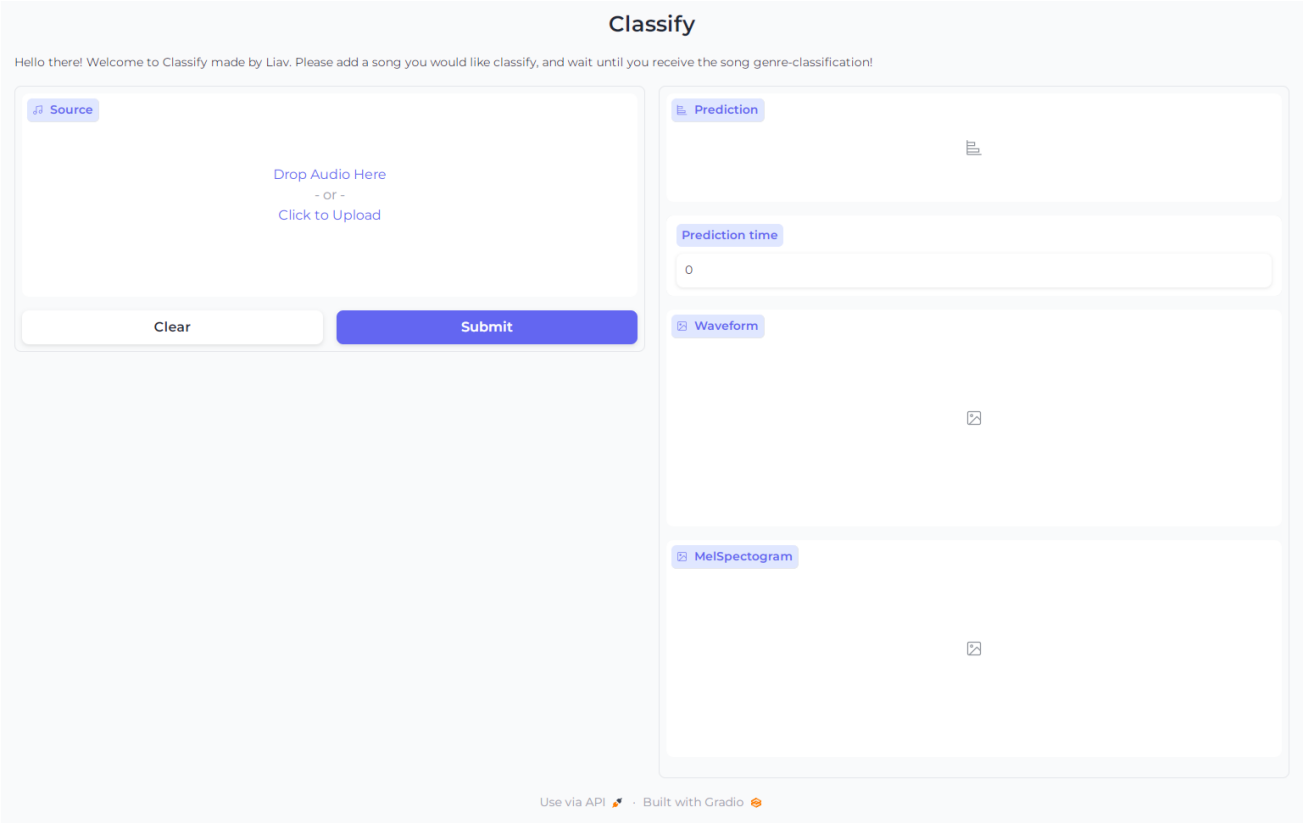

נוסיף לSource קובץ 3mp שנרצה לסווג -

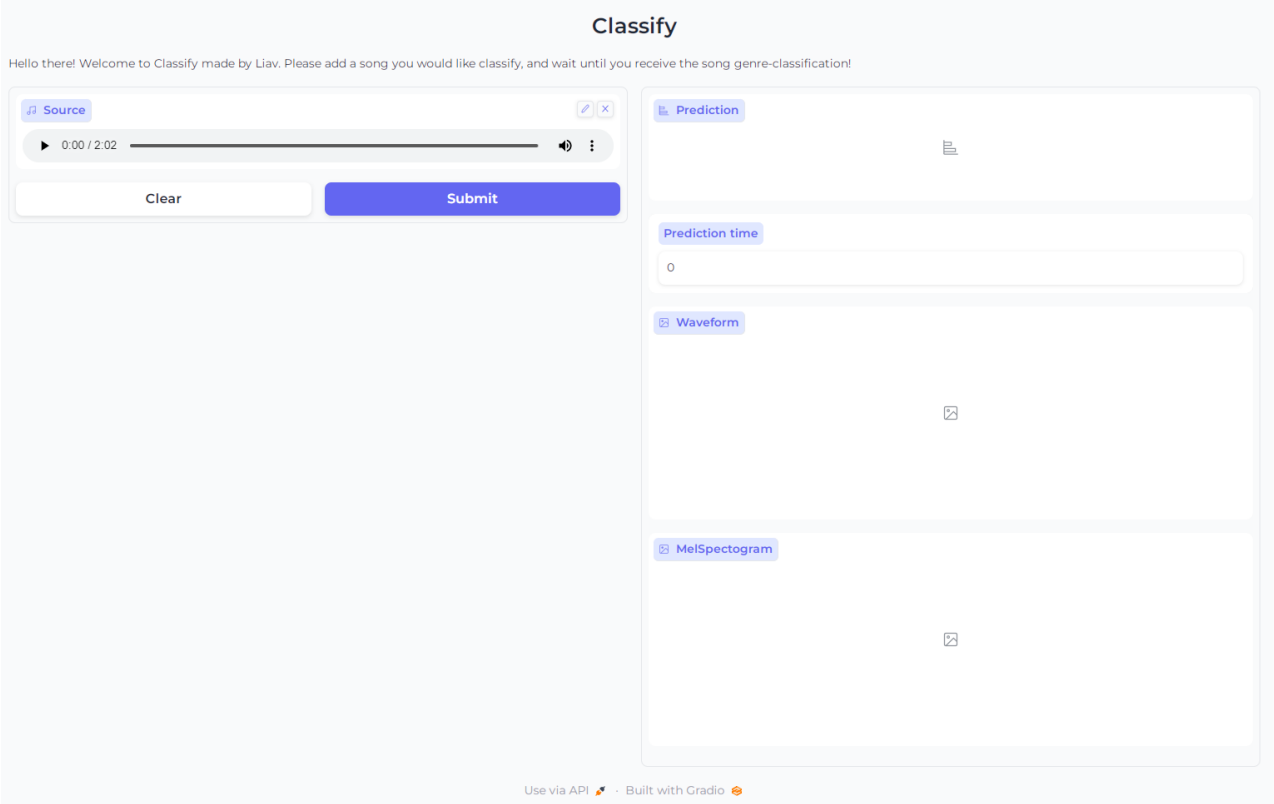

נלחץ על כפתור הSubmit ונחכה.

כעת, כפי שניתן לראות נקבל סיווג משוער(באחוזים) ביחד עם זמן החיזוי שלקח, ביחד עם תיאור ה-Waveplot של השיר וה-MelSpectogram. את התמונות ניתן להוריד למחשב. כעת, במידה ונרצה להוסיף שיר אחר, נלחץ על Clear, ונתחיל מהשלב הראשון.

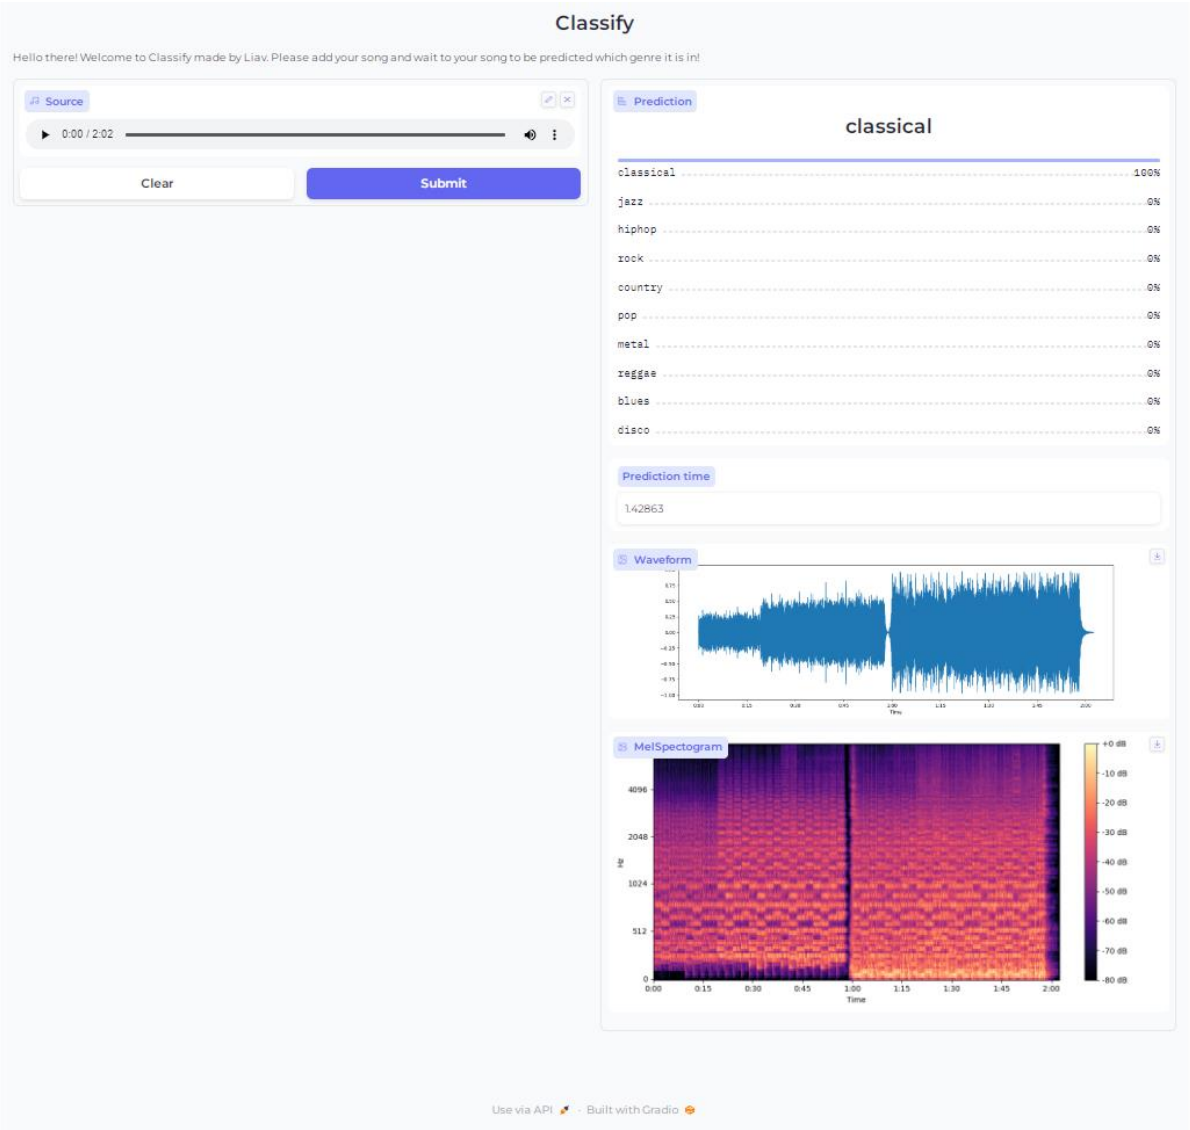

קישור ל-Github ובו נמצא הפרוייקט עצמו שנכתב בCollab, יחד עם קישורים לקבצים הנדרשים:https://github.com/L33TAv/GenreClassificationGTZAN-with-CNN

סיכום אישי / רפלקציה

הפרוייקט היה משמעותי מאוד בשבילי, העבודה על הפרויקט הייתה מאוד מאתגרת וגם מאוד מעניינת, מכיוון שבחרתי נושא שקרוב לליבי - מוזיקה. קיבלתי המון ערך, בין אם מדובר על ידע בלמידת מכונה, התעסקות בספריות שאינן בחומר הלימוד, ויחד עם תמיכתה של אולגה, למדתי רבות באופן עצמאי מתמטיקה ופיזיקה בכל הנוגע למוזיקה וסיווג במוזיקה. נוסף על כך, למדתי רבות על עצמי, על העצמאות והיכולות שלי להתמודד עם אתגרים בדרך. אני שמח מאוד שהגעתי להישגים גבוהים באחוזי הסיווג, אך ישנם מקומות נוספים שניתנים לשיפור - ביניהם ייעול הזמן שלוקח ליישום, הוספת ושיפור התוכן ועיצוב היישום, וייעול המודל לאחוזים גבוהים עוד יותר.

להמשך אני לוקח איתי את הכלים, של עבודה מסודרת, עמידה בזמנים, לא לוותר גם אם משהו לא עובד כי בסוף הצלחתי ועמדתי בקשיים ובמכשולים וכמובן, הידע הרב שרכשתי.

בין היתר, קשיים שהייתי צריך להתמודד איתם הם -

- עמידה בזמני ההגשות.
- ידע מתמטי ופיזיקלי בכל הנוגע למוזיקה ועריכת מוזיקה, שלא היה לי לפני כן.
- למידה ותכנות בחומר שלא הכרתי לפני כן.
- שינוי ובאגים בקוד, בין אם בפונקציות מתמטיות שהיו לא פשוטות לתקן או בבאג קטן בגלל עדכון באחת הספריות שבהן השתמשתי.

המסקנות שלי, במיוחד לאור המצב כיום בתחום למידת המכונה, שזהו חלק שהולך להיות אבן יסוד בעתיד של מדעי המחשב ובכלל ביום יום שלנו. בנוסף לכך, הבנתי המון על עצמי במהלך הדרך.

אילו הייתי מתחיל כיום, הייתי עובד באופן פעולה יותר מסודר (למשל: לסדר לפני כן את כל הקוד), והייתי חוקר יותר לעומק על הספריות והאמצעים שבהם אני משתמש ומוודא שניתן לעבוד איתם למטרותיי.

אם העבודה הייתה יותר יעילה עבורי, הייתי לדעתי מסיים יותר מוקדם ואולי גם מספיק להוסיף עוד דברים לפרוייקט כגון שיפור של המודל, או שיפור הויזואליות ביישום.

ביבליוגרפיה

- Bob, L. Sturm (2013). The GTZAN dataset: Its contents, its faults, their effects on evaluation, and its future use. https://arxiv.org/pdf/1306.1461.pdf
- Guangxiao, S., Zhijie W., Fang H., Shenyi D. (2017). Transfer Learning for Music Genre Classification. https://hal.inria.fr/hal-01820925/document
- VRUSHALI. (2021). Music Genre Classification Using CNN. https://www.kaggle.com/code/vrushaliingle/music-genre-classification-using-cnn/notebook
- Harsh M. (2021). Terms you need to know to start Speech Processing with Deep Learning. https://towardsdatascience.com/all-you-need-to-know-to-start-speech-processing-with-deep-learning-102c916edf62
- Tanveer, S. (2019). MFCC's Made Easy https://medium.com/@tanveer9812/mfccs-made-easy-7ef383006040